Proyecto de Innovacion 1

Fase 1 CRISP-ML(Q): comprension del negocio y los datos

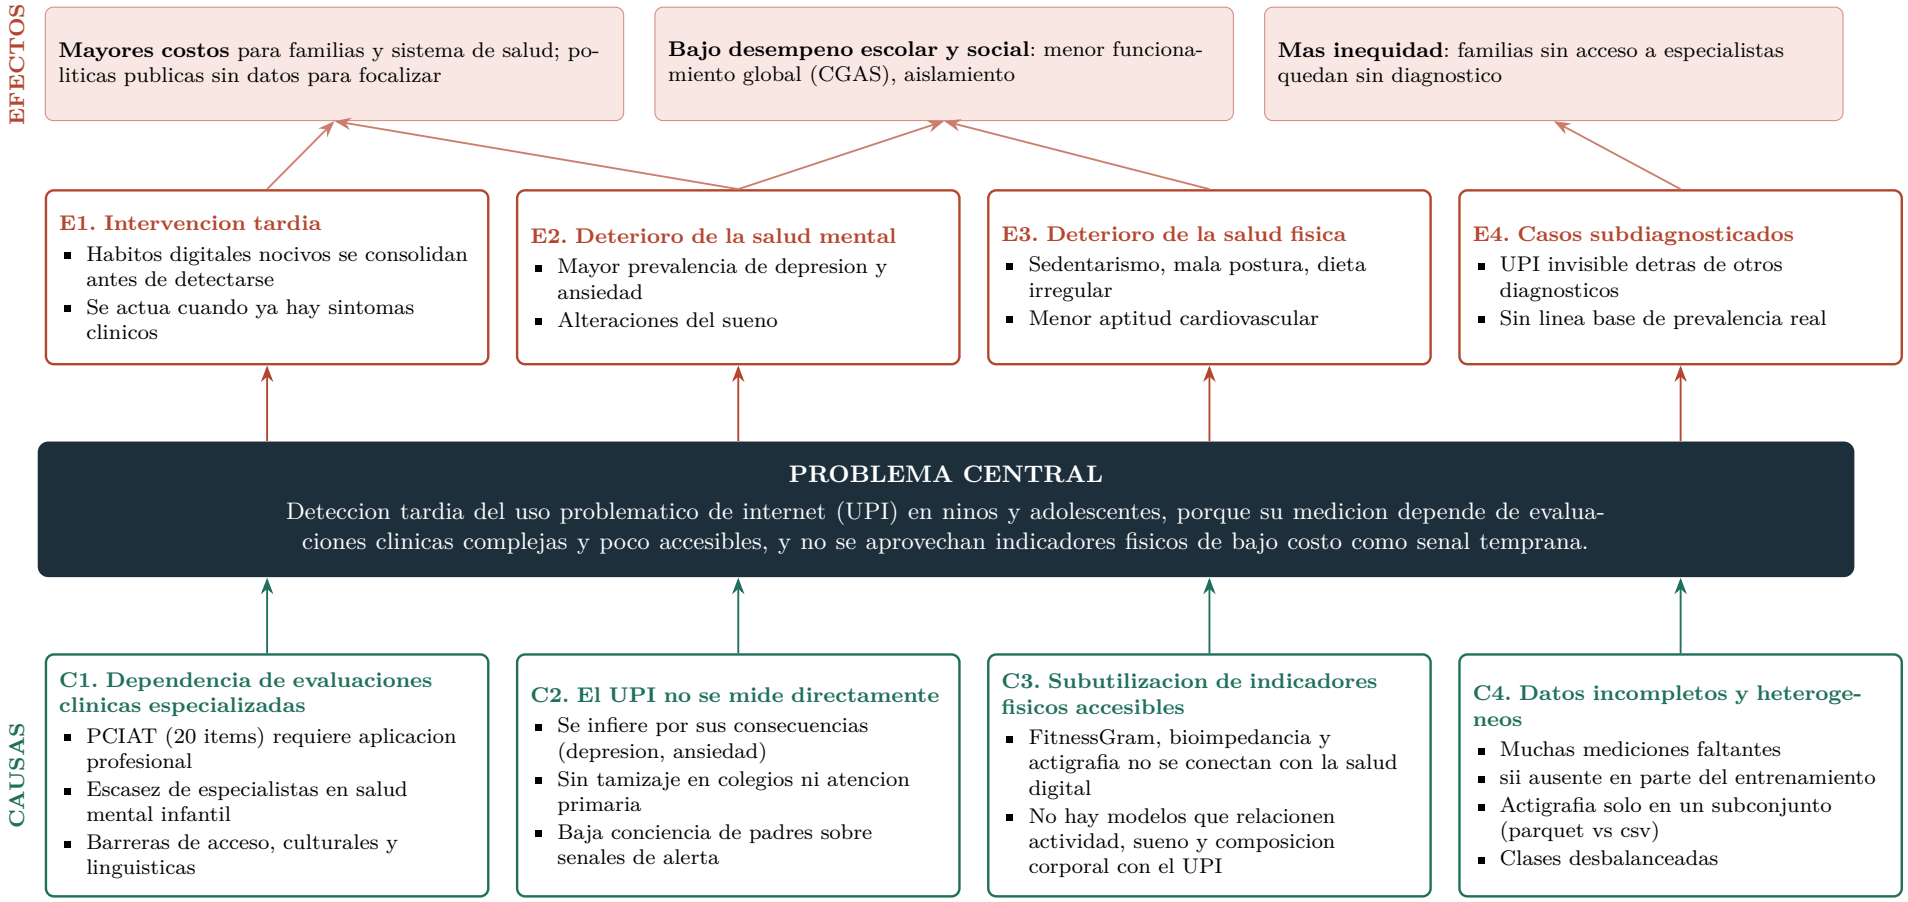
Uso problematico de internet en ninos y adolescentes

Rafael Santiago Bedoya, Jose Ricardo Florez
Wilson Panesso, Angie Giselle Perez

Contexto

El reto propuesto por Child Mind Institute y Healthy Brain Network (HBN) busca predecir el *Severity Impairment Index* (sii), medida estandar del uso problematico de internet (UPI), a partir de datos de actividad y aptitud fisica de jovenes entre 5 y 22 anos. El sii se deriva del cuestionario PCIAT: 0 = Ninguno, 1 = Leve, 2 = Moderado, 3 = Severo.

Arbol de problemas



1. Planteamiento del problema

En ninos y adolescentes de 5 a 22 anos, el uso problematico de internet se detecta tarde porque su medicion (PCIAT / sii) exige evaluacion clinica especializada, lo que genera barreras de acceso para muchas familias. Las medidas de aptitud fisica y actividad (FitnessGram, bioimpedancia, actigrafia de muneca, cuestionarios de actividad y sueno) son baratas y faciles de tomar, pero no se usan como senal temprana. La consecuencia es una intervencion tardia, con mayor deterioro de salud mental y fisica e inequidad en el diagnostico.

2. Datos que respaldan el problema

Dato	**Valor**	**Por que importa**
Muestra HBN	∼5.000 jovenes, 5–22 anos	Base clinica con evaluaciones fisicas y de uso de internet
Conjunto de prueba oculto	∼3.800 instancias	Escala real sobre la que se evalua el modelo
Instrumentos tabulares	11	Fuentes heterogeneas que hay que integrar (C3, C4)
Actigrafia	Hasta 30 dias, ventanas de 5 s	Senal objetiva de actividad y sueno, solo en un subconjunto
Train con sii etiquetado*	∼2.700 de ∼3.960	Justifica aprendizaje semi o no supervisado
Distribucion sii*	0: 58 %, 1: 27 %, 2: 14 %, 3: 1 %	Desbalance fuerte: los casos severos son los mas escasos

* Cifras aproximadas de la version publica de la competencia en Kaggle; verificar con `train.csv`.

3. Puntos de intervencion para IA

- **C3:** modelo predictivo del sii a partir de datos fisicos, de actividad y sueno (objetivo central del reto).
- **C4:** imputacion de faltantes, ingenieria de variables desde la actigrafia y manejo del desbalance de clases.
- **C1 y C2:** el modelo funciona como tamizaje de bajo costo que prioriza quien necesita evaluacion clinica; no reemplaza el diagnostico.

Conexion con CRISP-ML(Q)

Fase	**Aplicacion en este proyecto**
Comprension del negocio y datos	Este arbol, criterios de exito y verificacion de calidad de datos
Ingenieria de datos	Integrar csv + parquet, imputar faltantes, balancear clases (C4)
Ingenieria y evaluacion del modelo	Metrica ordinal (kappa cuadratico ponderado), robustez y explicabilidad (C3)
Garantia de calidad (riesgos)	Sesgo de muestra unica (Nueva York), fuga de informacion del PCIAT, sobreajuste

4. Reflexion

El arbol muestra que el problema no es la falta de un tratamiento, sino la falta de una senal temprana y accesible. Las causas C1 y C2 son estructurales y no se resuelven con IA, pero C3 y C4 si: hay datos fisicos baratos que hoy no se aprovechan y un reto tecnico claro en su calidad. Por eso el proyecto se enfoca en un modelo de tamizaje que prediga el sii con indicadores fisicos, como apoyo, no sustituto, de la evaluacion clinica.